



UNIVERSIDAD AUTÓNOMA DE YUCATÁN

ESTRUCTURA DE DATOS

PROYECTO UNIDAD 5

ANÁLISIS DE REDES CIENTÍFICAS

con grafos


Procesamiento de Lenguaje Natural

ÍNDICE

01	Descripción del problema y objetivos	04	Algoritmos aplicados
02	Recolección de datos	05	Resultados
03	Modelado del grafo	06	Conclusión

DESCRIPCIÓN DEL PROBLEMA Y OBJETIVOS

El proyecto consiste en construir y analizar una red de colaboración científica en el área de Procesamiento de Lenguaje Natural utilizando datos reales obtenidos desde la API de Semantic Scholar. El objetivo es estudiar cómo se conectan los investigadores mediante publicaciones compartidas y aplicar algoritmos de teoría de grafos para analizar la estructura de la red.



RECOLECCIÓN DE DATOS

SEMANTIC SCHOLAR API

Para construir la red científica se utilizaron datos reales obtenidos desde la API de Semantic Scholar, una plataforma académica que proporciona información sobre publicaciones científicas, autores y citas.

La API permitió consultar artículos relacionados con el área de Procesamiento de Lenguaje Natural (PLN).

¿Cómo se realizó?

La recolección de datos se realizó mediante peticiones HTTP desde Python utilizando la librería **Requests**.





01. Buscar

8 queries ejecutadas:

- "natural language processing"
- "computational linguistics"
- "language model"
- "text classification"
- "named entity recognition"
- "machine translation"
- "sentiment analysis"
- "question answering"




02. Pedir

100 papers por búsqueda

Pedimos a la API:

- Título del paper
- Año de publicación
- ID de cada autor
- Nombre de cada autor



3. Filtrar

Quitar datos duplicados

¿Por qué hay duplicados?

- Un paper sobre "language model" y "NLP" puede aparecer en ambas búsquedas.

Solución:

Set de paperIds vistos

- Si ya está → skip
- Si es nuevo → guardar



04. Guardar

Los datos descargados fueron almacenados localmente en formato JSON.

¿Por qué hay guardar?


- No descargar cada vez
- Resultados reproducibles
- Sin riesgo de bloqueo
- Facilidad de trabajar sin internet

RESULTADO

- **200** paper únicos
- **933** autores distintos



MODELADO DEL GRAFO



$G = (V, E, w) \rightarrow$ Grafo no dirigido ponderado



Nodos $\rightarrow$ Autores

- Cada investigador único equivale a un nodo
- Identificado por authorID de Semantic Scholar
- Atributos: name, paper_count, years



Aristas $\rightarrow$ Co-autorías

- Arista entre A y B si co-publicaron ≥ 1 paper juntos
- Co-autoría simétrica
- Generadas con combinations(autores, 2)





Peso $\rightarrow$ Papers compartidos

- $w(A, B) = \overset{E_s}{\text{número de papers en común}}$
- Peso alto = colaboración frecuente entre autores
- Para Dijkstra:
 - distancia = $1/\text{weight}$

ALGORITMOS APLICADOS

01. combinations (autores, 2)

Generar todos los pares de co-autores de cada paper → aristas del grafo.



03. nx.shortest_path (Dijkstra)

Camino más corto entre pares usando $\text{distance} = 1/\text{weight}$.

02. nx.connected_components

Detectar la componente gigante y las 118 pequeñas del grafo completo.



04. nx.average_shortest_path_length

Longitud promedio de caminos en el núcleo

5

`nx.diameter`

Camino más largo entre cualquier par de nodo

6

`nx.degree centrality`

¿Quién tiene más colaboradores directos?

7

`nx.betweenness centrality`

¿Qué investigador conecta diferentes grupos de investigación?

8

`nx.closeness centrality`

Mide qué tan cerca está un nodo del resto de la red

9

`community.best_partition (Louvain)`

Detección de comunidades por optimización de modularidad Q.



RESULTADOS

GRAFO COMPLETO: 933 AUTORES



Métricas de la red

Métrica	Resultado
Autores únicos (nodos)	933
Colaboraciones (aristas)	8130
Componentes conexas	119
Componente gigante	380 nodos (40.7%)
Autores aislados	9
Componentes pequeñas (2-5 nodos)	80
Componentes medianas (6-30 nodos)	28
Componentes grandes (>30 nodos)	2

NÚCLEO FILTRADO: SUBGRAFO DE LOS 150 AUTORES MÁS CONECTADOS

150 Nodos


3495 Aristas

0.35 Densidad

0.9481 Clustering
promedio

1.83 Longitud promedio
de caminos

4 Diámetro



CENTRALIDAD Y COMUNIDADES

Centralidad (Top autores)

Degree (Más colaboradores directos)

• Hady ElSahar	0.7651
• M. Costa-jussà	0.6242
• Loïc Barrault	0.6107



Betweenness (puentes entre subgrupos)

• Hady ElSahar	0.4259
• M. Costa-jussà	0.1970
• Loïc Barrault	0.0428

Comunidades identificadas

1

NLP multilingüe / MasakhaNER (48)

Hady ElSahar, Julia Kreutzer, I. Ezeani

2

Ecosistema NLLB (Meta AI) (48)

Jean Maillard, P.Y. Andrews, A. Mourachko

3

WMT / traducción estadística (27)


Philipp Koehn, Markus Freitag

4

Modelos pre-entrenados (18)

5

Grupo periférico de conexiones mixtas (9)



CONCLUSIÓN

El proyecto demostró que la teoría de grafos permite analizar redes científicas reales de manera eficiente. Mediante algoritmos de centralidad, caminos mínimos y detección de comunidades se identificó:

- Alta conectividad entre investigadores
- Una componente gigante que concentra gran parte de las colaboraciones
- Las métricas de centralidad permitieron identificar autores influyentes y nodos puente.
- El algoritmo Louvain detectó comunidades de investigación bien definidas.
- La red mostró propiedades de “mundo pequeño” gracias a sus caminos cortos y diámetro reducido.
- El alto clustering evidenció una fuerte colaboración entre investigadores.