



UADY
**UNIVERSIDAD
AUTÓNOMA
DE YUCATÁN**

Facultad de Matemáticas

Licenciatura en Ingeniería de Software

4° Semestre

Estructuras de Datos

Profesor: Dr. Jorge Carlos Reyes Magaña

Proyecto Unidad 5

Análisis de Redes Científicas con Grafos

Tema:

Procesamiento de Lenguaje Natural (PLN)

Equipo:

Couoh Concha Valeria Fernanda

González Chablé Said Alfredo

Maas Tuyub Ricardo Esteban

Tenorio Cauich Pedro Jesús

25 de mayo de 2026

1. Descripción del Problema

Este proyecto construye y analiza una red real de colaboración científica en el área de Procesamiento de Lenguaje Natural (PLN). Los datos provienen directamente de la API de Semantic Scholar.

La pregunta central es: ¿cómo se estructura la comunidad de investigadores que publican sobre PLN? ¿Existen grupos densamente conectados? ¿Hay autores que actúan como puentes entre subáreas? ¿Es la red densa o fragmentada?

Para responder esto modelamos las publicaciones científicas como una red de coautoría y le aplicamos los algoritmos clásicos del análisis de redes.

2. Modelado del Grafo

Se construyó un grafo no dirigido ponderado $G = (V, E, w)$ con la siguiente semántica:

V (nodos)	Cada autor único identificado por su authorId de Semantic Scholar. Atributos: name, paper_count y years.
E (aristas)	Existe una arista entre dos autores si han co-publicado al menos un paper. No dirigidas por simetría de la coautoría.
W (peso)	Número de papers compartidos por el par de autores. (Más peso = mayor colaboración).
distance	Atributo derivado: distance = $1 / \text{weight}$, usado en Dijkstra y closeness para que pares con más colaboraciones queden “más cerca” entre sí.

Filtrado para visualización: el grafo completo tiene 933 nodos y resulta visualmente ilegible y la mayoría de los autores aparecen en un solo paper. Para el análisis profundo y las visualizaciones se trabajó con el núcleo de los 150 autores más conectados dentro de la componente gigante. Esta decisión preserva la estructura comunitaria principal mientras hace el grafo legible. Las métricas de componentes conexas se calculan sobre el grafo completo para conservar el panorama global.

3. Datos y Algoritmos Utilizados

3.1 Recolección de Datos

Se ejecutaron 8 queries amplias sobre el endpoint */graph/v1/paper/search* de Semantic Scholar: "natural language processing", "computational linguistics", "language model", "text classification", "named entity recognition", "machine translation", "sentiment analysis" y "question answering". Por cada paper se almacenaron title, year, authors.authorId y authors.name. El dataset resultante contiene 200 papers únicos (deduplicados por paperId) y 933 autores distintos.

3.2 Algoritmos Implementados

Algoritmo	Librería	Propósito
Construcción incremental (combinations)	NetworkX + itertools	Genera aristas entre todos los pares de co-autores de cada paper.
nx.connected_components	NetworkX	Detecta la componente gigante y componentes pequeñas.
nx.shortest_path (Dijkstra)	NetworkX	Camino más corto entre pares de autores (distance = 1/weight).
nx.average_shortest_path_length y nx.diameter	NetworkX	Mide el "tamaño" de la red en el núcleo filtrado.
nx.degree_centrality	NetworkX	Popularidad local de cada autor.
nx.betweenness_centrality	NetworkX	Identifica puentes entre subgrupos.
nx.closeness_centrality	NetworkX	Centralidad respecto al resto de la red.
community.best_partition (Louvain)	python-louvain	Detección de comunidades por optimización de modularidad.
nx.spring_layout + matplotlib	NetworkX + matplotlib	Visualización estática del grafo.
pyvis.Network	pyvis	Visualización interactiva en HTML.

4. Resultados

4.1 Grafo Completo

Métrica	Valor
Nodos (autores únicos)	933
Aristas	8,130
Total de componentes conexas	119
Componente gigante	380 nodos (40.7% del grafo)
Autores aislados	9
Componentes pequeñas (2-5 nodos)	80
Componentes medianas (6-30 nodos)	28
Componentes grandes (>30 nodos)	2 (35 y 28 nodos)

El grafo exhibe la estructura típica de un campo científico: una componente dominante que concentra al 40% de los autores, rodeada de múltiples grupos satélite pequeños y autores aislados (papers de autor único).

4.2 Núcleo filtrado (top-150 por degree)

Métrica	Valor
Nodos	150
Aristas	3,945
Densidad	~0.35 (red densa)
Coefficiente de clustering promedio	0.9481
Longitud promedio de caminos	1.83 saltos
Diámetro	4
¿Es conexo?	Sí

El núcleo activo de PLN es extremadamente compacto: dos investigadores cualesquiera están separados por menos de 2 colaboraciones intermedias en promedio. El clustering cercano a 1 confirma que los colaboradores de un autor también tienden a colaborar entre sí, patrón esperado en coautoría académica donde un paper con muchos autores genera triángulos completos.

4.3 Centralidad

Posición	Top por Degree Centrality	Top por Betweenness Centrality
-----------------	----------------------------------	---------------------------------------

	Autor	Valor	Autor	Valor
1°	Hady ElSahar	0.7651	Hady ElSahar	0.4259
2°	M. Costa-jussà	0.6242	M. Costa-jussà	0.1970
3°	Loïc Barrault	0.6107	Julia Kreutzer	0.0735
4°	Holger Schwenk	0.5302	Guillaume Wenzek	0.0506
5°	Guillaume Wenzek	0.5302	Markus Freitag	0.0428

Hady ElSahar domina ambas centralidades, especialmente betweenness (0.4259), lo que la identifica como el conector central de toda la red. Markus Freitag es un puente clásico: aparece 5° en betweenness pero no en degree, lo que significa que conecta subgrupos sin tener el mayor número de colaboradores individuales.

4.4 Detección de Comunidades (Louvain)

Se detectaron 5 comunidades con una modularidad de 0.4560, valor por encima del umbral 0.3 que indica estructura comunitaria clara.

Comunidad	Tamaño	Autores Destacados	Interpretación
2	48	Hady ElSahar, Julia Kreutzer, I. Ezeani, Perez Ogayo	NLP multilingüe e idiomas de bajos recursos (MasakhaNER)
1	48	Jean Maillard, Pierre Yves Andrews, A. Mourachko	Ecosistema NLLB (Meta AI)
4	27	Autores WMT / traducción automática estadística	WMT — Sistemas de traducción automática
3	18	Modelos pre-entrenados y fine-tuning	Subárea de modelos neuronales de lenguaje
0	9	Grupo periférico	Grupo pequeño satélite

4.5 Visualizaciones Generadas

Archivo	Descripción
---------	-------------

grafo_completo.png	150 nodos del núcleo con colores por comunidad y tamaño por degree.
grafo_top_betweenness.png	Mismo layout pero destacando solo los 10 autores con mayor betweenness, etiquetados con nombre.
distribucion_grados.png	Distribución de grados del grafo completo en escala log-log, con la firma típica de una red libre de escala.
grafo_interactivo.html	Versión navegable con zoom, hover y arrastre para la presentación en vivo.

5. Conclusiones

Mundo pequeño extremo.	Dentro del núcleo activo de 150 autores, la longitud promedio de caminos es de 1.83 saltos y el diámetro es 4.
Estructura fragmentada con núcleo dominante.	El grafo completo tiene 119 componentes: una gigante de 380 nodos (40.7%), dos grandes (35 y 28) y 80 micro-componentes. Refleja la estructura típica de un campo maduro: un núcleo activo rodeado de equipos satélite.
Altísimo clustering (0.95).	Los colaboradores de un autor del núcleo también colaboran entre sí casi siempre, confirma la naturaleza triangular de la coautoría.
5 comunidades claramente definidas.	La modularidad de 0.456 corresponde a grupos reales: NLP multilingüe, NLLB, WMT y otros grupos.
Conectores clave identificados.	Hady ElSahar y M. Costa-jussà lideran todas las métricas de centralidad. Markus Freitag y C. Federmann son puentes estructurales.

Limitaciones del estudio: el dataset depende de las queries elegidas y solo dos de las ocho lograron completarse por el rate limit de la API. El filtrado a top-150 por degree privilegia a autores muy conectados y podría sesgar contra grupos pequeños relevantes.

Trabajo futuro: ampliar la recolección con API key autorizada, comparar la red de PLN con otra subárea para identificar patrones estructurales distintivos, y enriquecer las aristas con métricas de citación conjunta.